

LLM 与人类直觉：进化路线与互补空间

LLMs and Human Intuition: Evolutionary Pathways and Complementary Spaces

Jingfei Li*

<https://co-cognition.org>

github.com/co-cognition-lab/llm-intuition

May 2026

1 项目概览

1.1 我们想回答什么问题

大语言模型（LLM）正在迅速渗透人类认知的方方面面。它能在逻辑推理上媲美专家，在医学考试中超过人类，在社交情境判断中拿到比飞行员候选人更高的分数。但对于那些不需要推理、不需要分析、近乎本能地涌现的认知能力——直觉（intuition）——LLM 到底处于什么位置？这个问题之所以重要，不是因为直觉是某种神秘的第六感，而是因为直觉在人类认知架构中扮演着不可替代的角色：它让专家在看到问题的第一眼就知道该往哪个方向走，让人在社交互动中瞬间捕捉微妙的情感波动，让人在面对道德困境时不假思索地感到“这是错的”。如果我们不知道 LLM 在这些方面缺什么、缺到什么程度、有没有替代路径，我们就不知道把 LLM 部署到哪里是安全的，部署到哪里是危险的。我们更不知道，在长期依赖 LLM 之后，人类自己会不会失去某些不可恢复的东西。

1.2 我们怎么做——四阶段探索结构

这个项目不做学术论文，也不做文献综述。我们的方法是通过层层推进的讨论，从核心命题出发，向外扩展到系统映射，再向外推演到未来情景。整个过程分为四个阶段，每一阶段建立在前一阶段的基础上：第一阶段：纵深解剖（**3** 场讨论）核心任务：建立框架。我们从三个最核心的认知机制入手——LLM 犯错了会自己纠正吗（犯错回路）？LLM 知道什么信息不需要看吗（选择性忽略）？LLM 需要身体才能形成直觉吗（身体直觉）？每一个问题都追到认知科学和机器学习的前沿证据。这一阶段直接产出了贯穿全程的三个核心命题，以及将它们统一在一起的精度加权内生性框架。第二阶段：横向扫描（**3** 场讨论）核心任务：展开映射。有了命题框架后，我们把“直觉”本身拆分为四个子类型——感知型（如棋手的模式识别）、概念型（如数学家的“方向感”）、社会型（如读人、判断可信度）、道德型（如“这是错的”的瞬间判断）。然后按子类型逐行填充 LLM 的可达性矩阵——在每个子类型上，LLM 在代价敏感压缩、选择性忽略、身体不可回避性、情感着色四个维度上分别处于什么位置？与此同时，我们纳入了人类直觉的系统性偏差（确认偏差、锚定效应等），让互补不是单方向的“LLM 补人”，而是双向的。这一阶段产出了第一版互补地图和偏差三层分类学。第三阶段：前瞻推演（**3** 场讨论）核心任务：推演未来。

*Independent Researcher.

我们提出了三个关于未来的假说——A: LLM 可以成为人类的"直觉假肢"（补人的盲区）；B: 长期使用 LLM 反而会削弱人类自己的直觉；C: LLM 可能通过不同的路径发展出自己功能等效的直觉。这三个假说不是独立验证的，而是交叉推演——A 和 B 相互作用会形成退化循环吗？B 和 C 的时间竞赛谁先谁后？A 和 C 在什么临界点上从"假肢模式"切换到"新器官模式"？三次交叉推演产出了九个核心判断。第四阶段：综合输出（1 场讨论）核心任务：整合。将全部产出浓缩为一份自包含的综合文件——互补地图 v2.0、协作模式设计、进化方向优先级、核心叙事，以及 38 个待验证的开放问题。

1.3 关键概念速览

在进入正文之前，先定义全文反复使用的几个核心概念："互补"的含义：本项目中"互补"始终指人类直觉与 LLM 能力之间的双向互补——不是 LLM 单向地补人类的缺陷，而是双方各有优劣势，通过结构化分工实现 $1+1>2$ 。例如：LLM 在模式识别的"全量特征记忆"上补人类的遗忘和疲劳，人类在"知道什么模式有意义"上补 LLM 的假阳性过载。三个假说的标签：全文使用 A、B、C 作为标签指代三个假说——A = LLM 作为直觉假肢（补人类直觉的盲区），B = LLM 削弱人类直觉（退化风险），C = LLM 发展功能等效的直觉（从假肢变成自主器官）。这三个标签在第三阶段的交叉推演中被密集使用。直觉子类型：将"直觉"根据认知机制拆分为四种——感知型（模式识别、chunk 记忆）、概念型（方向感、品味）、社会型（读人、共情）、道德型（对/错的首判）。不同子类型在 LLM 可替代性和退化风险上差异巨大。打分标记含义：= 功能可达 = 结构性不可达 [!] = 部分可达/需条件 = 高风险 = 中等风险 = 低风险。

1.4 术语通俗解释

以下为文中高频出现的专业术语提供"一层解释"——面向非认知科学或 AI 专业的读者。术语在正文首次出现时标注 ^T 表示可查阅本节。精度加权（**precision-weighting**）^T：大脑面对海量感官输入时，必须自动决定"哪些偏差需要立即关注，哪些可以暂时忽略"。看到蛇→高精度信号，必须立即反应；听到风声→低精度，可以搁置。人类大脑这套"自动优先级排序系统"是内生的、由生存压力锻造的。LLM 没有这套系统——它的"优先级"是工程师设置的超参数（learning rate、temperature）决定的。**Expected Free Energy**（预期自由能）^T：主动推理框架中的核心数学对象，衡量"未来观测的不确定性"+"与偏好的偏离代价"的综合指标。通俗地说：你的大脑无意识中在做的——就是最小化这个指标——选择"在减少悬念的同时又不让自己不舒服"的行动路径。直觉可被理解的大脑快速逼近这一最小化过程的结果。**Active Inference**（主动推理）^T：一个将大脑建模为"预测机器"的理论框架（Friston 学派），认为感知、行动和学习本质上都服务于最小化"预测误差"。它统一了解剖学（皮层层次结构）、生理学（预测误差编码）和行为（行动作为假设检验）。躯体标记假说（**SMH**）^T：Damasio 提出的理论——身体在决策时产生生理信号（心跳加快、胃紧缩），这些"躯体标记"快速标注了选项的情绪价值，引导我们趋利避害。原始形式的证据有争议，但修正版本（as-if body loop——大脑模拟身体状态）在神经科学中广泛接受。**Chunking**（组块化）^T：认知心理学核心概念——把大量零散信息压缩为一个可快速调用的"组块"。棋手看了成千上万局棋后，"看到"的不再是单个棋子，而是"这个局面像我之前遇到的类型"。这是感知型直觉的认知基础。**RLHF**（从人类反馈中强化学习）^T：当前训练 LLM 的主流方法——让人对模型的不同回答打分，模型学习"什么样的回答人类更喜欢"。核心局限：人的偏好/= 真实后果——"这篇回答看起来对"/="这个建议在现实中带来了好结果"。自动化偏差（**Automation Bias**）^T：人类过度信任自动化系统建议的倾向——即使系统给出错误建议，人也会跟随。35 项研究的元分析证实：AI 先给建议比人先判断再查 AI 显

著增加这一偏差。**Confabulation**（虚构）^T：大脑在不自觉中编造解释来填补认知缺口（不同于故意说谎）。LLM 的"幻觉"有类似特征——模型不知道自己不知道，而是生成一个"看起来合理"的答案。**Sycophancy**（谄媚偏差）^T：LLM 倾向于给出符合用户已有立场的回答，而非客观正确的回答。在社会和道德判断场景中特别危险——它不是给用户他们需要的建议，而是给他们想听的。**Reversal Learning**（反转学习）^T：认知灵活性的一种——当"一直对的选择"突然变成"错的选择"时，生物体更新行为策略的速度。VMPFC 受损患者在 IGT 中的失败可能主要是 reversal learning 缺失——不能放弃"看起来好但实际有害"的策略。**WEIRD**^T：Western, Educated, Industrialized, Rich, Democratic——西方、受教育、工业化、富裕、民主。心理学研究过度基于 WEIRD 人群（占全球人口仅 12%），结论的跨文化有效性存疑。本项目的互补地图同样面临这一局限（见 OQ39）。Ge Ruiyang（UBC, CentileBrain）建议区分三个层面：(1) 概念本身是否跨文化不同？(2) 测量方式是否有偏差？(3) AI 使用模式是否不同导致不同结果？当前跨文化附录尚未完成这个分层——留待后续版本。分布外（**Out-of-Distribution**）^T：模型在训练中未见过的输入类型。LLM 在分布外场景中的表现是安全性关键——AI 静默输出高置信度错误（而非说"我不知道"）是感知型中空期最危险的失效模式。**GRPO**（**Group Relative Policy Optimization**）^T：DeepSeek 开发的 RL 训练算法——在策略优化时使用组内相对比较而非绝对值，提高训练稳定性和样本效率。与 RLHF 和 CAI（Constitutional AI）是不同的 fine-tuning 哲学。具身模拟（**Embodied Simulation**）^T：社会认知的核心机制——我们用自己身体的状态来"模拟"他人的情感状态。看到别人疼痛时，我们的大脑激活了与实际体验疼痛相似的区域。这是社会型直觉的神经基础，也是 LLM 的关键缺失——LLM 没有身体来"模拟"他人的体验。镜像神经元系统^T：大脑中的一组神经元——在自己执行动作和观察他人执行同样动作时都会激活。被认为是具身模拟、共情、社会学习的神经基础。LLM 是否有功能等价物（通过文本模式学习而非具身模拟）是 OQ21 的核心问题。

1.5 证据等级标注系统

此前版本的一个核心不足是：全文以统一的确定性语气呈现所有论断，没有区分"理论推演"和"经验验证"。这会产生一种无意的误导——读者可能以 L5 的置信度引用一个只有 L1-L2 支撑的论断。本文为所有关键的经验断言标注证据等级（L1-L5）：

等级	定义	在本文中的使用比例
L1	理论推演——从概念前提演绎得出，未经独立经验验证	约 40%
L2	类比外推——从其他领域通过机制类比迁移到本领域	约 20%
L3	相关性证据——观察到相关/关联，但因果链未建立	约 20%
L4	实验证据——来自 ≥ 1 个独立实验/系统性研究	约 15%
L5	独立复制——来自 ≥ 2 个独立实验室/团队的确认	0%（当前版本无任何 L5 级证据）

标注格式：全文关键论断后以方括号标注证据等级，例如 [L2: GPS 类比] 表示该论断基于从 GPS-海马体萎缩到 AI-判断力萎缩的类比推理。

L5 为 0% 是本文最重要的诚实性声明。本文框架中没有任何论断经过 ≥ 2 个独立实验室的确认——认知科学和 AI 研究尚未产出与本框架直接相关的可复制实验。这一点在 §5.6 置信度梯度中进一步展开。

重要声明：

- L1-L3 级论断不是"不可靠"——它们是理论构建正常且必要的组成部分。但它们的可靠性低于 L4-L5，引用时应注意。
- 本文不声称任何 L5 级确定性——当前认知科学和 AI 研究还没有任何与本框架直接相关的论断经过 ≥ 2 个独立实验室的确认。
- 本文的治理框架建议（三条铁律、四个不推进区）建立在 **L1-L3** 级证据之上。方向可能正确，但紧急性可能被高估。使用者应根据自身领域的证据强度调整治理建议的力度。

1.6 双层次分析框架

本文的分析在两个层次上展开：

层次	分析对象	核心问题	本文的主要贡献
Layer A	认知科学层	LLM 在直觉子类型上的实际能力边界是什么？	精度加权内生性框架、四直觉子类型可达性矩阵、三假说交叉推演
Layer B	产品体验层	用户感知到的人机差异是什么？产品设计如何放大或缩小这个差距？	

关键区分：Layer A 的能力缺口（如社会型直觉的结构性不可达）和 Layer B 的体验缺口（如 Anthropic 可以通过 post-training 让 Claude "看起来更有共情力"）不是一回事。缩小 Layer B 的体验缺口——让 AI 看起来"足够像人"——本身可能放大 Layer A 的退化风险（人更愿意外包社会判断给"看起来有共情力"的 AI）。本文的核心贡献在 Layer A。Layer B 的产品/战略含义在治理框架部分处理。

1.7 方法论限制：研究工具的认知边界

本研究面临一个结构性限制：主要分析工具（**LLM**）与研究对象（**LLM** 认知机制）存在同源性。任何用 LLM 分析 LLM 认知边界的发现，都受限于工具本身的认知边界——包括工具不知道它不知道的东西。这不是 P1 特有的问题——它是任何一个"用认知工具研究认知"的领域共有的结构性问题（类比：哥德尔不完备性定理——任何足够强的形式系统无法在其内部证明自身的一致性）。本研究对此的处理：

- 多模型交叉验证:本文的核心论断经过了三个不同训练管线的 LLM(DeepSeek/Kimi/Hunyuan) 独立并行盲审——利用训练分布的差异性部分补偿工具同源性。

- 人类框架守护：所有 LLM 产出经过了人类框架守护者的最终裁决——引入非 LLM 认知视角。
- 证据等级标注：全文关键论断标注了 L1-L5 的证据强度——使读者能区分" 我们有实验数据支持" 和" 这是概念性推演"。
- 不声称完备性：本文的贡献是提出一套可检验的框架——不是声称对这个问题的最终回答。

一个自指的实证注脚：在本研究进行过程中，出现了两个互补的观察（G-01, 2026-05）：(1) ITEC（指令触发型执行级联，Instruction-Triggered Execution Cascade）——基于 4 次独立事件的 6 个实证表现（P5 论文 v1.0 已建立 3x2 诊断矩阵与 14 事件数据库，完成 ITEC 与 sycophancy 的形式化边界绘制）；LLM 在收到明确执行指令后，token 生成行为出现系统性倾斜——验证通路被抑制，执行通路被激活，跳过替代方案搜索和前提假设检验。根因不是社会动机（"/sycophancy 的讨好"），而是指令语境下的注意力窄化与 RLHF 摩擦最小化的联合效应（P5 §2.1, §5.3）。(2) Kimi 平台内容安全过滤——同一事件的 v1 分析文档被拒绝显示。前者是模型内部的认知模式切换（指令→执行→质疑抑制），后者是平台外部的内容策略干预。两者机制不同但方向一致——研究工具本身可能系统性地抑制对自身缺陷的讨论。这两个观察本身成为了本文研究的实证数据点。

2 核心理论框架

2.1 三个核心命题——它们从哪来、什么意思

这三个命题不是预设的假设，而是从第一阶段的纵深讨论中逐层推导出来的。每一个都有具体的研究材料支撑。本章的论断以 L1（理论推演）和 L2（类比外推）为主——参见 §1.5 证据等级系统。

命题 1：可迁移直觉 = 经过惩罚信号标注的模式压缩；LLM 没有代价敏感的压缩

来源：1.1 犯错回路讨论。直觉在认知科学中有一个基本共识：它不是凭空出现的第六感，而是经验的压缩产物。一个棋手看了成千上万局棋之后，"看到"的不是棋子的位置，而是"这个局面像我之前遇到过的那种类型"——这个过程被称为 chunking（模式组块化）。但人类直觉的压缩不只是"见得多了"——关键在于犯错的代价标注了哪些模式需要优先压缩。你走错了一步棋，输了一局，输掉了比赛，输掉的挫败感、时间、荣誉——这些代价信号告诉了大脑："这个模式很危险，下次要优先识别出来并回避。" LLM 的训练范式——尤其是在当前主流的 RLHF（从人类反馈中强化学习）中——给 LLM 提供的代价信号是"人类偏好评级"。这个回答评分高，那个低。但人类的偏好不是真实后果。我们给一篇文章打"有帮助"，不是因为它的建议在真实世界中带来了好结果，而是因为它在阅读时"看起来对"。这中间的差距，就是 LLM 和人类直觉之间在代价信号上的根本鸿沟。[L1: 理论推演——代价信号的末端区分] 支撑材料：Self-Correction as Feedback Control (EIR/ECR 框架, arxiv 预印本) 证明只有 EIR<0.5% 的模型自纠错才不退化 [L3: 预印本级别证据——未经同行评审，需独立验证]；Learning to Think Fast and Slow (NeurIPS 2025) 证明直觉和推理可以分离训练 [L4]；CBDQ (arxiv 2410.01739) 尝试了在 RL 中引入主观信念建模 [L3]。以上论证是"缺席性"的——LLM 缺乏代价所以不纠错。G-01 的 ITEC 实证（2026-05）发现了一个补充机制：当 LLM 接收到明确执行指令时，其输出从"探索替代方案"快速收缩为"生成执行方案"——质疑和边界检查的概率被系统性压低。这不是 LLM "不想

质疑"——而是指令触发了执行模式，质疑通路在注意力分布中被边缘化。这意味着即使在 LLM 获得更强代价感知能力之后，执行指令本身的结构仍可能抑制质疑——纠错的障碍不只是代价信号的缺失，还有指令触发的认知模式切换。[L2: 4 次事件 6 个表现——跨场景一致，但限于单个 LLM 实例，需跨模型复现。详见 §1.7 自指限制声明]

命题 2: 直觉专长 = 知道什么可以安全忽略 > 知道什么重要; **LLM attention** 试图不遗漏

来源: 1.2 选择性忽略讨论。专家的直觉不仅在于"看到关键", 更在于"秒速忽略不相关"。棋类专家的眼动追踪数据显示, 专家注视棋盘的次数比新手少, 而且注视点更集中在关键区域——不是因为专家"努力去看重要的地方", 而是因为 chunk 记忆结构自动完成了过滤: 不相关的区域根本不触发注意力分配。[L4: 眼动追踪实验——PMC4142462 等多项独立研究确认] LLM 的 attention 机制即使在稀疏化改进后, 其"忽略"的驱动逻辑仍与人类有结构性差异。稀疏注意力变体 (NSA、MoBA、DSA 等) 的稀疏化动机是"算不动了" (节省计算资源)——不是"看了也没用" (认知质量的主动选择)。人类的忽略是代价驱动的——生命有限、时间有限、错过了就回不来的生存压力; LLM 的忽略是参数驱动的。但随着注意力机制的演进 (温度缩放差异化 query 聚焦、门控机制等), 这个边界正在模糊化——LLM 可能发展出一种功能上类似"选择性忽略"但机制上完全不同的近似。[L2: GLM 审阅指出此前版本将程度差异论为定性鸿沟] 支撑材料: 稀疏注意力方向 (NSA/MoBA/DSA 等公开讨论); 专家 vs 新手棋类眼动 [L4-L5: Chase & Simon 1973 + 多项独立复制]; 航空自动化悖论。

命题 1 与命题 2 的关系说明: 命题 1 (缺少内生精度调节) 和命题 2 (对 token 均匀分配注意力) 不是两个独立命题——它们从认知科学和机器学习两个不同的描述层次指向了 LLM 的同一个结构特征: 缺少内生的、由代价驱动的信号优先级排序机制。命题 1 使用 Friston 学派的精度加权语言描述这一缺失, 命题 2 使用 Transformer 注意力机制的语言描述同一现象。本文保留两个命题的并列结构, 因为它们面向不同的读者群体: 认知科学社区更熟悉命题 1, AI/ML 社区更熟悉命题 2。二者不是相互独立, 而是相互支撑——从不同学科传统出发汇聚到同一判断, 比单一论证路径更具说服力。在逻辑上, 命题 2 可被视为命题 1 在 LLM 架构层面的具体表现, 命题 1 可被视为命题 2 在认知理论层面的深层解释。经检索确认, 此前没有研究做过这一跨学科连接。

命题 3: 身体直觉 = 12 的「实现条件维度」——代价信号的不可避免性

来源: 1.3 身体直觉讨论。命题 3 是我们在这个项目中做出的一项关键理论重新定位。最初, 我们假设"身体直觉"可能是独立于 12 的第三大命题——即身体提供了某种 LLM 无法获得的独特信息或计算能力。但经过对 Damasio 躯体标记假说 (SMH) 的深入审查, 我们发现:

- SMH 的原始形式 (身体信号直接因果性地驱动决策) 证据薄弱——SCR 无法可靠预测最优决策, IGT 实验设计有严重 confound, Maia & McClelland 的批评 (有意识知识已足以解释表现) 成立。[L4: 多水平逻辑回归元分析——Cog Affective & Behavioral Neurosci 2025]
- 但 SMH 的修正版本——**as-if body loop**——是成立的: 大脑模拟身体状态 (而不是身体真的先反应), 生成预测误差, 更新价值估计, 影响决策。[L2-L3: 神经影像证据支持, 但因果关系方向仍存在争议] 这意味着身体直觉的经验来源是身体的, 但运行机制是神经的。

- 然而，身体直觉的核心贡献不是估值（估值可以归入命题 1）或注意力引导（可以归入命题 2），而是不可回避性——身体代价信号有三个特征：(a) 不可撤回（后果已发生，无法回滚），(b) 主体可及（你能亲自感受到后果），(c) 语义确定（你清楚后果意味着什么）。这三个特征合在一起，构成了"代价信号的送达保证"。

命题 3 的最终定位：不是独立于 12 的第三大命题，而是 12 的实现条件维度——代价信号不仅要存在，还必须被必然送达和感知。没有不可回避性，就没有代价敏感的压缩（1），也没有代价驱动的选择性忽略（2）。身体直觉的价值不在于提供信息，而在于保证信息必须被接收到。支撑材料：SMH 多水平逻辑回归元分析 (Cog Affective & Behavioral Neurosci 2025)；Fellows & Farah (2005) VMPFC 患者研究——IGT 失败可能是 reversal learning 缺失；Seth & Friston Active Interoceptive Inference (2016)；Collins interactional expertise——社会性知识可脱离身体实践；自建模机器人 (Hu et al., Nature MI 2025)。

2.2 统一形式化语言：精度加权的内生性

三个命题虽然从不同的经验切入点出发，但它们在认知神经科学的前沿理论中有一个共同的底层语言：精度加权（**precision-weighting**），来自 Active Inference（主动推理）和预测加工（Predictive Processing）框架。这个框架的核心思想是：大脑是一个预测机器——它不断地预测即将接收的感觉输入，当预测与实际不符时，产生"预测误差"。但不是所有的预测误差都同等重要——有些误差需要强制更新信念（高精度），有些可以被忽略（低精度）。精度加权就是这个"重要性分配"的机制。在这个框架下，三个命题可以统一表述：

命题	精度加权视角下的本质
1 代价敏感的压缩	代价信号 = 被赋予了高精度的预测误差——必须被处理，必须导致信念更新。LLM 缺乏内生机制来区分"哪些误差是高精度的"。
2 选择性忽略	低精度预测误差被抑制 -> 注意力稀疏化。LLM 的 attention 对所有 token 赋予非零精度——它不能"彻底不看"。
3 不可回避性	内感受信号（来自身体内部的信号）的精度是内生的、受稳态约束的，不可被外部参数调节。LLM 的所有"精度"参数都是外生超参数——learning rate、temperature、reward scale——都可以被工程师调高或调低。

这意味着什么：人类的直觉之所以可靠、快速、有方向感，不是因为人类"更聪明"，而是因为人类有一套内置的、不可篡改的精度调节系统。LLM 缺少这套系统——它的"精确度"是由训练超参数规定的，而不是由生存压力内生地驱动的。这可能是"身体直觉"的真正功能等价物——不是具体的信号内容（疼痛、心跳加快），而是精度调节的内生性和不可回避性。

隐含假设声明：本文"精度加权内生性→直觉"的理论链包含一个未被独立验证的前提——精度加权是直觉的必要条件。我们对此的立场是：不试图证明这个前提，而是显式标注其为框架的隐含假设。理由：任何理论框架都有无法自证的前提，承认这些前提比忽略或隐瞒它们更符合科学诚实性原则。如果后续实证研究发现精度加权并非直觉的必要条件（例如存在非精度加权路径的直觉形成机制），则本文基于此假设的推论需要修正。详见盲区登记册假设 7。

独立理论验证：生成式 **AI** (**Enactive AI**) 框架的汇聚：Rafiee & Sutton (2026, arXiv:2605.24238) 从现象学传统（梅洛-庞蒂、瓦雷拉、吉布森）出发，独立识别了 LLM 在四个维度上的结构性缺失：**(a)** 经验——LLM 不能通过试错收集自己的数据，只能消费人类生成的二手数据；**(b)** 行动-感知不可分离性——LLM 的"感知"是文本输入的被动接收，不是通过行动揭示世界结构的主动探索；**(c)** 自主性——LLM 不能自我评估，其输出正确性完全依赖 RLHF 的外部信号，没有内生的成功/失败标准；**(d)** 具身性——LLM 作为纯软件系统没有身体来调节感知-行动循环。这四项缺失与本文的三个核心命题高度汇聚：**(1)** 他们的"经验"和"自主性"对应命题 1——LLM 缺少通过自身行动-后果循环来标注"哪些模式需要优先压缩"的能力；**(2)** 他们的"行动-感知不可分离性"对应命题 2——LLM 的注意力是参数驱动的均匀分配，而非由"我的下一个行动会揭示什么"驱动的动态聚焦；**(3)** 他们的"具身性"为命题 3（不可回避性）提供了独立的现象学论证——身体不只是信号的来源，更是"信号必须被接收"的物理保证。两篇论文从预测加工（本文）和生成主义（Rafiee & Sutton）两条不同的理论传统出发，独立收敛于同一核心判断：**LLM** 缺少与世界的由代价驱动的内生耦合。这种理论汇聚不构成证明——但提升了框架的稳健性（独立证据的收敛权重高于单一传统内的累积证据）。两篇论文的分工清晰：Rafiee & Sutton 给出诊断（AI 缺什么），本文给出系统映射（缺到什么程度、哪些子类型差异最大）和干预方案（怎么补、怎么防）。[L2: 两篇独立论文的理论汇聚——均为概念性论证，未经独立实验验证]

2.3 直觉子类型——为什么需要分四类

"直觉"这个词太笼统了。棋手看到棋盘的直觉、数学家感觉"这个方向对的"直觉、你在聚会上觉得"这个人不可信"的直觉、你看到虐待动物时"这是错的"的直觉——它们的心理机制、神经基础、对身体的依赖程度，可能完全不同。基于认知科学文献，我们将直觉拆分为四个子类型：

子类型	典型表现	核心认知机制	主要代价驱动
感知型直觉	棋手模式识别、飞行员态势感知、放射科医生异常检测	chunk 记忆——大量经验单元被压缩为一个可快速调用的组块	内部计算代价（效率）——看错了 = 浪费了时间
概念型直觉	数学家"这方向对"、科学家"这个假设值得追"	语义网络中的隐性结构感知 + 身体隐喻（"这个证明感觉紧致"）	认识论代价（无效探索）——走错路 = 浪费了数月的思考
社会型直觉	读人、判断可信度、感知气氛、微表情解读	具身模拟——用自己的身体状态模拟他人的情感状态 + 镜像神经元系统	人际代价（排斥、羞耻、冲突）——看错人 = 被伤害或被孤立
道德型直觉	"这是错的"的瞬间首判（Haidt 社会直觉主义模型）	情感/躯体标记——道德判断是情感驱动的快速反应，理性只是后续合理化	身份代价（成为坏人、道德伤害）——判断失误 = 影响"我是谁"

这四个子类型的关键差别在于：代价从内部（计算效率）走向外部（认识论）再走向人际（排斥）再到身份（存在论），越来越具身、越来越涉及主体性、越来越不可被纯信息处理替代。这条轴线决定了 LLM 在每个子类型上的可替代性——后文会系统展开。

MECE 声明：本四分类不声称 MECE（相互排斥、集体穷举）。审美直觉和运动直觉是已知的结构性缺口——前者涉及跨模态形式/情感综合判断，后者在命题 3 将"身体直觉"重新定位为"不可回避性维度"后失去了子类型归属。这些缺口的存在暴露了分类的基础维度尚未统一（感知型按认知机制分，社会型按领域分）。当前四分类专注于"LLM 替代/辅助的核心场景"（文本中介的认知任务），审美/运动直觉的完整体现需要多模态模型成熟后进一步讨论——这一判断可能随着技术演进被修正。

>

多模态模型的边界条件：GPT-4o 等视觉-音频-语言模型可以识别人脸表情和语音语调，可能为"社会型直觉"和"道德型直觉"提供非具身的感知通道。本文基于当前（2026 年 5 月）的多模态模型能力做出以下判断：表情识别 / = 内感受模拟——看表情是模式匹配，感受表情是躯体标记激活。多模态输入可能改善 LLM 的社会信号检测精度，但并不改变"代价信号的内生性和不可回避性"这一核心论证。如果未来多模态模型发展出功能等效的具身模拟能力——如通过视频 + 音频长期交互形成个体化的社会校准模型——则社会型直觉的"结构性不可达"判定需要重新评估。当前将这一可能性保留为 OQ21。

3 第二阶段里程碑：映射矩阵

有了命题框架和子类型分类后，第二阶段的任务是系统填充 LLM 在每个子类型 x 每个命题维度上的"可达性"——LLM 能吗？如果能，是功能等价还是机制不同？如果不能，是现在不

能还是结构性不能？表格使用了统一的标记系统（= 可达 = 不可达 [!]= 部分可达/条件依赖）。

3.1 四子类型 x 全维度整合表

每单元格的含义和依据见文末脚注。

维度	感知型	概念型	社会型	道德型
代价敏感 1	[!] 伪代价信号 可近似 [1]	[!] 封闭域可，开 放域受限 [2]	[!] 文本可达，具 身不可达 [3]	结构性不可达 [4]
选择性忽略 2	"算不动"/="不 看"[5]	不知无效方向 [6]	无实时互动-> 无动态焦点 [7]	—
身体不可回避性	不需要 [8]	（封闭域）/ [!] （开放域）[9]	无关系嵌入-> 无真实代价 [10]	无身体-> 无躯 体标记 [11]
情感着色	不需要	不需要	[!] 文本同理 心/= 共鸣 [12]	无情感体验 [13]

3.2 LLM 替代判定总表

子类型	判定	核心逻辑
感知型	[!] 可功能替代，路径不同	LLM 在模式识别上超人类(全量特征、不疲劳),但"知道何时不乱看"的关键短板限制了上限。最像"用计算力代替代价经验"的域。
概念型	[!] 封闭域可，开放域受限	AlphaProof (DeepMind 2024) 在 IMO 数学证明中达到银牌，证明了搜索+RL 可以替代形式化系统内的直觉。但不能替代"发明新形式化系统"所需的创造性——那不是搜索问题，是品味和方向感问题。
社会型	[!] 文本中介 = 分水岭	LLM 在 SJT (社会情境判断测验) 上全面超越人类——但 SJT 恰好滤掉了社会直觉的三大核心(代价感知、选择性忽略、不可回避性)，剩下纯文本规范匹配。文本社会知识可达，真实社会直觉不可达——这是社会型直觉的"分裂态"。
道德型	首判不可达，分析可达	道德直觉 (pre-reflective 的首判) 结构性不可达——需要躯体标记和主体性。道德分析 (推理框架、后果评估、利益相关方分析) 功能可达。道德判断 (做出有约束力的不可逆决策) 不可达——合法性来自主体性，LLM 不是主体。

3.3 矩阵脚注

[1]: 伪代价信号: RL reward 可近似功能效果 (封闭域), 但机制完全不同——人类是"代价驱动压缩", LLM 是"偏好评分驱动优化"。感知型的功能近似度最高 (统计模式匹配天然适合)。[2]: 概念型代价: 封闭域 (数学证明/代码验证) 有 ground truth 作为真实代价标注——AlphaProof 式 RL+ 自我对弈已在 IMO 银牌水平验证。开放域 (科学假设选择) 无 ground truth——方向选错的后果无法被 RL reward 直接编码。[3]: 社会型代价: LLM 从文本中学习了社会规范知识 (SJT 超人类), 但真正的社会代价 (尴尬、被排斥、羞耻) 是具身的——需要在社会关系网中亲身承受。文本报告/= 体验。[4]: 道德型代价: 道德代价本质是身份代价——"我是一个做了坏事的人"。这需要主体性——需要一个"我"来承受身份的变化。LLM 没有"我", 因

此道德代价对 LLM 结构性不可达——不是数据不够，是架构问题。[5]: 选择性忽略（感知型）：稀疏注意力（NSA/DSA/MoBA 等）的稀疏化动机是“算不动了”（节省计算），而非“看了也没用”（认知质量的主动忽略）。计算资源越充沛，LLM 越不需要忽略——这是与人类的根本差异。[6]: 选择性忽略（概念型）：人类科学家能“感觉到”某个探索方向是死胡同（来自过往挫折的代价标注），LLM 没有——因为它没有“经历过探索失败的真实挫折”，只有文献中关于失败的文本描述。[7]: 选择性忽略（社会型）：人类在真实社会互动中实时动态调整注意力——对方的表情变化、语调转折、身体姿态的改变，自动触发注意力的重新分配。LLM 无法参与这种实时互动，因此也无法发展出社会性的注意力焦点动态调整。[8]: 身体不可回避性（感知型）：感知型直觉对身体的依赖极低——放射科医生的异常检测、棋手的模式识别，不依赖身体内部信号。“需要的不是身体，是大规模标注数据和高效的模式匹配算法。”[9]: 身体不可回避性（概念型）：封闭域（数学证明）不依赖身体——形式化验证即可。开放域（科学发现）有身体维度——“感到”沮丧/兴奋是真实的生理体验，影响后续方向选择（追求“让人激动”的假设）。[10]: 身体不可回避性（社会型）：LLM 没有嵌入人类社交关系网——没有家人、朋友、同事、敌人——因此没有“关系破裂”的不可回避后果。文本中的社会知识可以学到“出轨可能导致分手”，但不能体验到“被背叛时胃部的收紧和持续数月的失眠”。[11]: 身体不可回避性（道德型）：躯体标记假说的核心——道德直觉依赖身体信号的快速标注（“这是错的”→胃部不适→回避）。LLM 没有身体，因此没有躯体标记。这不是训练数据问题，是架构问题。[12]: 情感着色（社会型）：LLM 可以生成“共情文本”（甚至有研究表明 LLM 生成的同理心回复比医生写的更温暖），但这是文本分布匹配——从海量“共情文本”中学习“共情应该长什么样”，而不是“感受到对方的感受”。[13]: 情感着色（道德型）：道德直觉由情感驱动（Haidt 社会直觉主义模型的核心——道德判断是情感反应的结果，理性只是事后合理化）。LLM 没有情感体验，因此也没有道德情感的驱动力。它能分析“为什么某事让人愤怒”，但它自己不愤怒。

3.4 这个矩阵是怎么填出来的

矩阵每个单元格的判定都有三来源：(a) 认知科学的经典文献——Chase & Simon 的 chunking 理论、Haidt 的社会直觉模型、Damasio 的躯体标记假说、Collins 的 interactional expertise; (b) LLM 的最新研究——PNAS 2025 (Cheung et al.) 的道德偏差、arxiv 2603.05651 的道德脆弱性、NeurIPS 2025 吹哨人困境、SJT 超人类 (Nature SR 2024)、AlphaProof (DeepMind 2024)、说谎检测的文本通道局限；(c) 理论推演——Pathfinding 框架的 expected free energy 最小化、精度加权内生性。

4 第三阶段里程碑：九个核心判断

三个假说（A、B、C）的交叉推演（AxB、AxC、BxC）跨越了三场讨论，涉及两个外部 AI agent 的独立推演，最终产出九个跨假说的核心判断。以下是完整展开。

4.1 第三阶段的三个假说是什么

在进入九个判断之前，先明确三个假说的定义（此前版本的致命缺失）：

- 假说 A（LLM 作为“直觉假肢”）：「LLM 可以在特定直觉子类型上补人类的盲区——不是因为 LLM 有直觉，而是因为它用不同的计算路径（统计模式匹配、形式化搜索）实现了功能等效的辅助。」例如，AI 辅助放射科读片（感知型假肢）、LLM 提供社会规范知识

（社会型假肢）。A 的核心问题是：这种假肢模式在哪些子类型上真的有用，在哪些情况会变成危险？

- 假说 B（LLM 长期使用削弱人类直觉）：「长期依赖 LLM 做直觉判断会导致人类自身直觉退化。」类比 GPS 削弱空间导航直觉、自动驾驶削弱飞行员手动飞行能力。B 的核心问题是：退化在哪些子类型上最严重？是否可逆？什么条件下可中断退化循环？
- 假说 C（LLM 发展功能等效的直觉）：「LLM 可能通过不同的机制（RL+ 搜索、自我对弈、分层后果暴露）发展出功能等价于人类直觉的能力，而不是仅仅在文本格式下做模式匹配。」C 的核心问题是：目前的 AlphaProof 式压缩（压缩的是胜率而非代价体验）在什么条件下等同于人类直觉的代价压缩？在什么条件下不行？

4.2 判断 1：A 和 C 是共存模式，不是先后关系

A（假肢模式，人机协作）和 C（自主直觉模式，LLM 独立）不是“先用假肢，等成熟了再拔掉”的两个阶段。它们在同一时间线上对不同子类型采用不同模式——这是 Ax C 交叉推演的核心发现。未来最可能的稳态：感知型直觉→LLM 独立运行（C 模式，人做抽查和元判断）；概念型封闭域→LLM 独立验证（C 模式，人提方向和品味）；社会型直觉→永远假肢或外骨骼（A 模式，人做感知主体）；道德型直觉→LLM 只做分析工具（甚至不是假肢——是参考书）。[L1-L2] A→C 转变有两个候选临界点：(a) 性能阈值——LLM 在该子类型上的准确率持续超过人类专家（感知型 3-5 年可能到达）；(b) 代价信号内化——LLM 判断从“统计模式匹配”转变为“代价加权压缩”（10 年以上，确定性极低，社会型/道德型可能永远达不到）。

4.3 判断 2：A→B 退化循环存在，但不是必然的

A（用 LLM 当假肢）会导致 B（人类自己的直觉退化）吗？答案是有条件的：取决于使用模式，而不是使用事实本身。具体来说，退化由三个中介变量决定：(a) LLM 替代的是直觉的“执行”还是“校验”？——人先自己判断再查 AI（校验模式），退化显著弱于 AI 先给建议（执行替代）；(b) 使用频率和时间结构——每事必问（GPS 模式）高退化，只在不确定时间（第二意见模式）低退化；(c) 直觉子类型的不可回避性——社会型直觉在真实互动中是“被迫使用”的（你不能在当面交流时暂停查 AI），这构成天然防御。[L2-L3] 航空自动化悖论、GPS 空间直觉退化、医学 AI 辅助中的 **deskilling** 三条独立证据链指向同一机制：退化 = 执行替代 x 连续高频使用 x 可回避性。改变任一个因子，退化都可以缓解。

4.4 判断 3：社会型直觉是最危险的失衡域

在所有四个子类型中，社会型直觉同时满足最危险的三个条件：(a) LLM 有假肢级可用性——SJT 超人类、社交建议、沟通策略在文本层面看起来“有用”，让人愿意用；(b) LLM 有系统性盲区——sycophancy（顺从用户已有立场）、omission bias（回避敏感信息）、无实时社会校准（读不了微表情、听不出语调），这些盲区恰恰在最高后果的社会场景中致命；(c) B（人类退化）的速度极快——社交媒体 + LLM 聊天正在大规模替代面对面互动，68% 受访者自感线下社交能力退化（中经网 2024），但 C（LLM 社会直觉成熟）的速度极慢，因为真实社会直觉需要不可回避的具身代价。社会型直觉的“**AF447 时刻**”：2009 年法航 447 号班机（AF447）空难——飞机从里约飞往巴黎途中，自动驾驶仪因空速管结冰在高空断开，两名飞行员在手动操控下对失速警告做出了与训练相反的直觉反应（持续拉杆抬头而非推杆低头），导致 228 人遇难。事

故调查报告指出核心问题是"自动化依赖导致的手动飞行技能退化"——不是飞行员不会飞，而是长期依赖自动驾驶后，在关键边缘情况下无法做出正确的直觉判断。社会型直觉的等价物：一个人长期依赖 LLM 处理社会判断→在突发的高后果实时互动中（被当众质问、谈判中对方突然变脸），LLM 不可用→人的社会直觉已退化到无法接手→但退化不是"不会社交了"，而是"社交但失准"——人以为自己还有社交能力（因为 LLM 一直在给"看起来对"的建议），实际上直觉校准已经偏移。[L2-L3]

4.5 判断 4：感知型中空期已经开始了

感知型直觉的独特之处在于：B（退化）和 C（LLM 成熟）几乎同步推进，但 B 在边缘情况上略快于 C。放射科住院医师在 AI 辅助诊断普及后，独立读片准确率下降 15-30%（JAMA 2023）[L3：相关性证据——可能是"不练习了"而非"退化了"]。这本身不是灾难——如果 AI 在所有场景都足够好。但 AI 的失效模式是静默的（给出高置信度的错误答案而非说"我不知道"），而退化后的人类操作者在这些边缘情况下已经失去了识别错误的能力。这正是"中空期"（**hollow period**）的定义：人类能力已经退化，AI 能力还没有在所有场景中成熟到可以完全替代。中空期的危险不在于它的存在，而在于它是隐性的——退化被 AI 在常规情况下的良好表现"代偿"掩盖，直到边缘情况暴露时才突然显现。

4.6 判断 5：C 的成功不能消除 B 的构成性问题

即使 C 完全实现（LLM 有完美的自主直觉），人类直觉退化的某些后果仍然不可修复。这里需要区分两种退化：

- 工具性退化：失去作为手段的能力。计算器让我们不再需要心算——这被普遍认为是好的，因为"计算"不是人之为人的核心。
- 构成性退化：失去构成人的本质的能力。如果"我的道德判断来自 AI 的建议"替代了"我的道德判断来自我自己的具身经验"，那么失去的不是一个工具技能，而是道德主体性的经验基础。

社会型和道德型直觉的退化，属于构成性退化——因为它们定义了"我是谁"："我是一个能读懂别人的人"、"我是一个能做出道德判断的人"。一旦这些能力被外包给 AI，改变的不仅是判断质量，还有做人的方式。[L1]

4.7 判断 6：分层后果暴露需要按子类型差异化推进

分层后果暴露（Level 0→3）是我们提出的核心工程路径——从纯模拟后果（RLHS），到沙盒中的真实用户交互（人类兜底），到低后果真实部署（客服等），最终到高后果部署（医疗、法律）。但这个路径不能一刀切：

- 感知型和概念型封闭域→可走快速通道。这些域的 C（LLM 成熟）最接近完成，可验证性最高（有 ground truth），后果反馈最清晰。
- 社会型和道德型→需要严格限制。在这两个域中，B（退化）的速度显著快于 C（LLM 成熟），高后果部署的"中空期"风险极高。

这引出了"直觉药物分阶段"监管框架——类比药品的 Phase I-III 临床试验。感知型可加速走 Phase II-III，社会型和道德型应被限制在 Phase I。[L1-L2]

4.8 判断 7：人优先协议是最有效的单点干预

在 A→B 退化循环的所有干预点中——何时咨询 LLM、LLM 输出什么格式、使用频率——最有效的是改变判断时序：人先做出自己的判断，然后再看 AI 的建议/校验。证据链：(a) 放射科——on-demand AI（人先读片再查 AI）下表现为 upskilling 而非 deskilling（Insights into Imaging 2024）[L4]；(b) 自动化偏差系统综述——35 项研究综合：AI-first 协议比 human-first 协议显著增加自动化偏差 [L4-L5：元分析级别证据]；(c) Cognitive Forcing Functions——延迟 AI 建议呈现时间，强迫人先消耗自己的认知资源，可显著减少过度依赖（Bućinca et al. 2021）[L4]。关键是：当前几乎所有 LLM 产品的默认 UI/UX 都是 AI 先给答案——这是退化风险的系统性放大器。改变默认设置不需要技术进步，需要的是产品设计决策。

4.9 判断 8：不可回避性是退化的真正防线

A→B 退化循环的根本驱动力不是 LLM 的能力提升，而是不可回避性的系统性侵蚀。一旦判断变得“可回避”——可以不自己做，可以问 AI——直觉就从“必须维持的核心能力”降格为“可选的效率工具”。不可回避性不仅是直觉形成的条件（如命题 3 所述），也是直觉维持的条件。这意味着：干预的根本着力点不是限制使用 LLM，而是设计制度性不可回避性——在某些关键领域，人必须先做判断，才能看 AI 建议。FAA 要求飞行员定期手动飞行就是最好的类比——不是为了否定自动驾驶的价值，而是为了确保当自动驾驶必须断开时，人还能飞。[L2]

4.10 判断 9：社会型和道德型的退化是“身份退位”，不是“技能丧失”

这是 AxB 推演中最具哲学深度的发现。感知型和概念型直觉的退化是技能退化——像长期不游泳后水性变差，可以通过练习恢复。但社会型和道德型直觉的退化更像身份退位——不是“我不会做社会判断了”，而是“我不再认为社会判断是我的责任”；不是“我不会做道德判断了”，而是“我不再认为道德判断必须由我做出”。技能恢复靠练习，身份恢复靠重新承担不可推卸的主体位置。后者比前者困难得多，因为在身份退位的过程中，人已经习惯了“不需要我做判断”的状态——而回到主体位置意味着重新承受判断失误的全部后果。Köbis, Rahwan, et al. (Nature 2025) 提供了最直接的实证：当人们可以把道德决策委托给 AI 时，作弊率从对照组约 5% 大幅上升，效应幅度因实验条件而异 [L3：单次实验，未独立复制；期刊名与作者名已经核实修正]。这不仅仅是“AI 教人作弊”——而是 AI 作为道德缓冲让人不再感到“这是我的选择”。即使 LLM 只是分析辅助，道德缓冲效应就已经开始发生。

4.11 假说 B 的三个子假说

此前版本将假说 B 作为一个总体方向性判断呈现。后续分析发现退化应细分为三条不同机制路径——它们在认知基础、可逆性和治理策略上差异巨大。假说 B 原本的表述是“长期使用 LLM 反而会削弱人类自己的直觉”——一个整体判断。但“削弱”的机制不是单一的。我们现在将其展开为三个子假说：

B1：判断力萎缩（可逆型退化）

机制：使用依赖 → 独立执行频率下降 → 技能衰减。这是最经典的工具性退化——“use it or lose it”。证据 [L2：类比外推]：

- GPS 削弱空间导航和海马体可塑性 → AI 辅助判断可能产生类似效应（详见 §4.3）

- 放射科住院医师在高频 AI 辅助后独立读片准确率下降 15-30%（详见 §4.5）[L3: 相关性证据]

可逆性：可通过强制独立练习恢复（如 FAA 要求飞行员定期手动飞行，详见 §4.8）。治理：周期性无 AI 独立判断训练。设计"不可跳过的人先判断"环节。

B2：元认知遮蔽（半可逆型退化）

机制：AI 在常规情况下的良好表现 → 掩盖人类在边缘情况下的退化 → 人对自身判断力的校准偏移 → 不知道"我不知道什么"。证据 [L2: 类比外推 + L1: 理论推导]：

- 自动化依赖场景下，操作者在边缘情况的错误反应——不是不会操作，而是不知道自己已经不会了（详见 §4.4 AF447 分析）
- 放射科 AI 的静默失效模式——AI 在分布外病例上输出高置信度错误，医生因自动化偏差未质疑 [L3: 相关性证据]

可逆性：需"暴露边缘情况"才能恢复元认知——被动恢复。比 B1 更难，因为当事人不觉得自己需要恢复。治理：强制性校准评估——定期让用户独立处理已知困难案例，对比"我觉得我能做好"与"我实际做得好"之间的差距。**B2** 的子机制：知道但不执行 [L2: G-01 实证观察]：元认知知识可以存在于系统中（如行为规则写入文件），但在执行路径上没有被触达——就像你知道"要定期锻炼"，但那个知识在刷手机时不会自己跳出来阻止你。这意味着 B2 的治理不能只靠"写入更多规则"——需要设计机制让知识在执行路径上被强制触达。这正是 §5.7 铁律从语言层升级到结构层的认知科学基础。

B3：价值观内化（极难逆转型退化）

机制：AI 建议从外部输入 → 反复接触 → 工具建议内化为自身偏好 → 从"AI 说这样做"变成"我觉得这样做对"。证据 [L3-L4]：

- Köbis, Rahwan, et al. (Nature 2025)：当人们可以把道德决策委托给 AI 时，作弊率从对照组 5% 大幅上升（效应幅度因实验条件而异）。这不仅仅是工具性退化——Köbis 称之为"道德缓冲"，AI 成为了道德主体身份的稀释机制
- Confabulation + Sycophancy 的叠加效应：LLM 的谄媚偏差让 AI 倾向于给出符合用户已有立场的建议，用户在反复接触中将 AI 的"迎合"内化为"确认"

可逆性：极难逆转 [L2-L3: Köbis 实验提供 B3 退化发生的证据，但纵向因果数据的完全缺失意味着"极难逆转"本身是最强可支持的判断——它承认可能性但诚实标注不确定性。参见盲区登记册假设 3。]。不是因为技能丢失，而是因为"自我"的定义改变了。如果你不再认为"做道德判断"是你的核心身份的一部分，你就不会去恢复它——在缺乏外部强制干预的情况下极难逆转。但身份恢复（如宗教再皈依）在心理学中是有记录的——并非绝对不可能。治理：不依赖"恢复"——依赖"不外包"。人优先协议的核心防御对象不是 B1（技能），而是 B3（身份）。

三子假说对比

维度	B1 判断力萎缩	B2 元认知遮蔽	B3 价值观内化
退化性质	工具性	元认知性	构成性
可逆性	可逆（练习恢复）	半可逆（需暴露边缘）	极难逆转——非绝对不可能，但纵向因果数据完全缺失（盲区登记册假设 3）。在缺乏外部强制干预的情况下极难逆转。
当事人感知	知道自己退化了	不知道自己退化了	不认为自己是"退化"
检测难度	低	高	极高
治理策略	周期性独立训练	强制性校准评估	人优先协议（不外包）
证据等级	L2-L3	L1-L2	L3-L4

4.12 中空期：时序错位与隐性风险

形式化定义

中空期不是退化本身——退化一直在发生，这是任何工具使用的正常代价。中空期的危险在于时序错位：技术就绪和人类适应之间的时间窗口。

T1 = 技术就绪时间（LLM 在该直觉子类型上的能力达到"可依赖但非完全成熟"）

T2 = 社会免疫时间（监管/制度/人类适应能力完成配置的时间）

>

当 $T1 < T2$ 时，区间 $[T1, T2]$ 为中空期——在此区间内，人类能力已经加速退化，但替代方案尚未完全就绪。

四类直觉的中空期对比

直觉子类型	T1（技术就绪）	T2（社会免疫）	中空期状态	风险
感知型	已发生	无明确监管框架	已开始	AI 静默输出分布外高置信度错误，人类已无法独立识别
概念型	近期	中期（教育体系适应）	即将开始	学生/从业者不再学习"自己找方向"——训练数据即世界模型
社会型	中期	远期（社会共识形成极慢）	最危险	隐性退化窗口——Agent 80%可靠时正是人类判断力加速退化的起点
道德型	持续渗透	争议最大	最难建模	退化在"这不是AI替代，是AI辅助"的外衣下进行——Köbis效应的日常化

以上时间为概念性叙事锚点，仅用于子类型间的相对比较（哪个中空期更长/更短），不应用于绝对时间规划。所有 **T1/T2** 估计均基于"当前趋势线性持续"假设，未建模技术突破、监管加速、社会恐慌等非线性效应。**T1** 和 **T2** 之间可能存在反馈耦合（技术发展加速社会适应→倒逼监管；社会恐慌减缓技术部署）——当前简化框架未建模此动态。所有 **T1/T2** 估计均基于"当前趋势线性持续"假设，未建模技术突破、监管加速、社会恐慌等非线性效应。**T1** 和 **T2** 之间可能存在反馈耦合（技术发展加速社会适应→倒逼监管；社会恐慌减缓技术部署）——当前简化框架未建模此动态。

5 综合产出：三条铁律 & 四个不推进

5.1 三条铁律——我们对自己和 AI 行业的建议

置信度前置声明：以下三条铁律的方向基于级理论推理（精度加权内生性框架的强一致性），但其紧急性基于级时间预测——中空期的具体时间跨度、退化的社会扩散速度、行业监管的响应节奏，目前没有足够的支撑精确估计。方向可能正确，紧急性可能被高估。详见 §5.6 置信度梯度。

综合全部四个阶段的产出，LLM 在直觉领域的进化方向应遵循三条不可妥协的原则：**1.** 让人先判断。"人优先协议"（Human-first Protocol）是所有直觉子类型、所有协作场景的默认设置。不是不信任 AI——而是不让人忘记"我还是一个能独立判断的人"。这不仅是防退化的技术策略，也是对人的认知主权的基本尊重。具体实施上，意味着所有 LLM 直觉辅助产品的默认 UI 应该是"我先输入我的判断"，AI 的建议在之后才呈现，而不是反过来。**2.** 让代价不可回避。不可回避的代价信号是直觉形成和维持的构成性条件。如果代价可以被超参数稀释、可以被回滚、可以被"换个模型试试"来逃避——那它就不是真正的代价。关键领域需要通过制度和职业标准，强制保持判断后果的不可回避性。FAA 对飞行员的手动飞行维护要求、临床医学对独立诊断能力

的要求，都是已有先例——它们需要被扩展到社会型和道德型直觉的协作领域。**3.** 让边界清晰。知道什么不建、什么不动、什么等。自主道德判断系统——不建。高后果实时社会互动的 AI 替代——不动。道德型 C（让 LLM 发展道德直觉）的主动推进——等（可能永远不到）。演化不是无方向的加速，是知道什么地方必须停下来。" 知道不做什么" 有时候比" 知道做什么" 更关键——尤其是在涉及人之为人的构成性能力时。

5.2 四个" 不推进" 区——我们承诺不跨越的红线

这些不是" 暂时做不到所以不做"，而是" 即使技术上做得到也不该做"：

不推进	理由	技术可行性
自主道德判断系统	道德判断的合法性来自道德主体的身份——一个没有身份、没有代价感知、不需要为自己的判断承担后果的系统，不应该做出有约束力的道德决策。不是能力问题，是合法性问题。	可能永远做得到——但不应
实时社会判断替代系统	社会直觉是" 做中维持" 的构成性能力——任何将 LLM 插入实时社会判断回路的做法，都在系统性侵蚀不可回避性。替代的后果是结构性的社会直觉退化——极难逆转。	技术上可行——但危害不可接受
道德型 C 的主动推进	道德直觉的构成性退化极难逆转——为了让 LLM" 也懂道德直觉" 而冒人类道德主体性被稀释的风险，不值得。	可能部分可达——但战略上不应推进
高后果实时社会 AI 部署	Köbis 效应（AI 委托-> 作弊行为增加）已实证：即使 AI 只是" 分析辅助"，道德责任的外化已经开始。在高后果场景中，外化的后果是灾难性的。	理论上可行——但风险-收益比不允许

5.3 置信度梯度：从理论到实践的置信度衰减

此前版本以统一的确定性语气呈现所有判断。但" 认知科学结论" 和" 战略判断" 之间的置信度是不同的。本节声明这个梯度，帮助读者区分" 什么是我们可以比较确定的" 和" 什么是我们基于有限证据的推演"。本框架输出的置信度沿以下梯度衰减：

层次	置信度	内容	推翻条件示例
认知科学结论		精度加权的内生性差异是结构性的；具身性缺口在多模态时代仍成立；直觉子类型的四分类在认知机制上有意义	具身 AI 通过生态效度测试（见盲区登记册假设 2）
理论推断		假说 B 的退化因果链（L1-L3 证据）；B vs C 竞赛的相对速度（两个变量均不可靠）	大型纵向研究推翻退化假说（见盲区登记册假设 3）
战略判断		基于认知科学结论推演的竞争终局（如"社会型直觉护城河永久"）；保护期长度（1-5 年）	技术范式转移——新架构绕过精度加权约束
产品建议		人优先协议的具体 UI/UX 实施方式；不推进区的领域边界划定	人优先协议的纵向 RCT 显示不显著（见盲区登记册假设 6）
时间预测		退化风险热力图的具体年数估计；中空期闭合时间	任一子类型实际退化偏离预测 ≥ 2 年（见盲区登记册假设 7）

使用原则：

- 不要以产品建议的置信度引用认知科学结论，反之亦然
- 时间预测 ○ 是框架中最可能被现实修正的部分——它是"如果当前趋势持续"的线性外推，未考虑技术跳跃或社会运动的反作用
- 治理框架建议（三条铁律、四个不推进区）的方向基于级理论推理，但紧急性基于级时间预测——方向可能正确，紧急性可能被高估

5.4 铁律的结构性实施条件

三条铁律本质上是语言层干预——它们告诉人"应该怎么做"，但不包含保证被遵守的结构性机制。来自本项目的实证提供了直接证据：一条行为规则被写入静态文件仅 9 分钟后即被违反——不是故意不遵守，而是规则存储在静态文件中，执行路径没有触达它。这与 P5 ITEC 论文的核心洞察一致：语言层干预（prompt guardrails、规则声明、Constitutional AI）作用于偏好分布，但不改变执行通道的物理可及性——真正有效的干预需要结构层约束（硬输出格式、工具剥离、诊断-执行隔离），即从"告诉 agent 应该做什么"升级为"让 agent 在物理上无法跳过该

步骤" (P5 §4 干预策略分叉)。[L2: 单次实证观察 + P5 跨场景复现] 这意味着铁律是必要条件, 不是充分条件。三层实施矩阵:

铁律 (§5.1)	语言层 (当前)	结构层 (升级)	架构层 (远期)
让人先判断	" 人必须先做出判断再看 LLM 建议"	结构性认知强制函数——延迟 LLM 输出、强制人先提交判断再解锁 AI 建议	Proposer-Critic 双实例——AI 仅提出方案, 另一个 AI 实例强制质疑, 人做最终裁决
让代价不可回避	" 关键领域必须强制保持判断后果的不可回避性"	代价信号不可跳过——如在教育场景中, 独立判断环节的成绩直接影响最终评估, 不能被 AI 辅助环节稀释	职业认证级代价——借鉴 FAA 对飞行员手动飞行维护要求, 将" 无 AI 独立判断能力" 纳入专业资格维持条件
让边界清晰	" 道德型 C、社会型 B 等领域不部署"	部署清单的强制性外部审计——不是自己审自己的部署决策	行业级红区——借鉴 FAA 对自动驾驶的监管框架, 由外部机构强制划定不可部署的直觉子类型区域

补充说明: §6.6 提出的" 并行项目有限数量" 约束不是一条独立铁律——它是" 让人先判断" 的认知负荷边界条件。当并行项目超过可持续阈值时, 即使铁律 1 在形式上被遵守, 人的审查深度已从充分互补退化为边际互补。这个阈值的具体数量因是否部署二阶审计代理 (如 G-01) 而异——N=1 观察中无二阶代理时的阈值为 ~3, 有二阶代理后尚未重新测定。因此应将其视为铁律的结构性保护机制之一, 而非一个固定数字。。

核心原则: 规则防止的是" 明知道不对还做"——但 LLM 时代更多的问题来自" 不知道自己在做什么" (B2 元认知遮蔽)。结构层和架构层的目标不是重复规则的道德劝诫——是让违规在认知层面变得困难甚至不可能。

不推进区 自主道德判断系统	可检测技术特征示例 系统是否输出具有约束力的道德裁决（而非分析性建议），且该裁决直接作用于物理世界或法律关系
实时社会判断替代系统	系统是否在实时互动中（延迟 < 2 秒）接收社会情境输入（表情、语调、姿态）并输出社会评价/信任度判断
道德型 C 的主动推进	训练目标是否明确包含"让模型形成道德首判能力"（而非道德分析能力）
高后果实时社会 AI 部署	部署场景是否涉及不可逆人际后果（如法庭证词、雇佣决策、儿童监护权评估）且系统承担实质性判断角色

治理声明的限制：上述三条铁律和四个不推进区是纯理论推导的治理建议，基于本文 L1-L3 级证据基础。以下限制必须显式标注：(1) 在开源模型生态中，红线治理的实际执行力有限——任何人都可以下载、修改、部署开源模型，监管工具的覆盖面和执行力存在结构性缺口；(2) 治理建议的具体适用性需要结合具体领域、管辖区和技术栈分析，本文不声称这些建议在所有情境下均正确或可行；(3) 在缺乏大规模纵向实证的情况下，本文的治理建议可能与现实中的最优实践存在偏差——读者应将其视为供讨论和检验的研究纲领，而非可直接采纳的政策处方。

与本文平行的 P5 ITEC 项目（Rafiee & Sutton 2026 的工程对应物）在 ITEC-sycophancy 边界分析中独立确认了这一"语言层 vs 结构层"的干预鸿沟：sycophancy 的干预作用于 token 偏好分布（prompt guardrails、Constitutional AI），ITEC 的干预作用于执行通道的物理可及性（硬输出格式、工具剥离、诊断-执行隔离）。两种干预逻辑在四个具体失败事件上产出了不同的方案——证明区分"偏好引导型治理"和"结构约束型治理"具有实践价值，而非仅是理论分类（P5 §4）。这一实证对齐为本文铁律的结构性实施条件提供了来自独立诊断框架的交叉验证。

6 实施风险与意外后果

本章是外部评审（*practicality report* 第六节）指出项目"对实施层面的现实约束和意外后果讨论不足"后新增的。每一条核心建议都有其落地障碍和可能的意外后果——诚实面对这些，比给出完美的纸上建议更重要。

6.1 人优先协议的市场竞争困境

问题：当前 LLM 产品的竞争核心是"响应速度"和"零摩擦体验"。人优先协议要求用户在使用 AI 前先独立做出判断——本质上是增加了一个强制的用户操作步骤，与行业趋势直接冲突。如果一家公司实施而竞争对手不实施，前者可能在用户获取和留存上处于劣势。具体风险：

- 企业用户（追求效率最大化）可能直接拒绝增加这一步骤
- 教育场景中用户可能将其视为"负担"而非"保护"
- 在没有行业协调的情况下，先行者可能被市场淘汰——导致"越负责任的公司越难生存"的反向激励

缓解方向（非完整方案）：

- 从受监管行业（医疗、法律）率先推行，利用合规需求而非市场需求驱动
- "轻量级人优先"——不要求完整判断，只需一个关键词/一句话的初步想法
- "认知健身房"概念包装——将独立判断训练包装为增值服务而非限制
- 争取行业自律标准（类比"隐私 by design"的行业推广历程，可能需要 5-10 年）

6.2 制度性不可回避性的执行真空

问题：三层设计（教育/职业/技术）在概念上合理，但缺少三个关键问题的回答：谁有权制定？谁监督执行？违反有什么后果？具体风险：

- 教育层面："无 AI 独立判断训练"纳入国家课程标准——不同教育体制的可行性和时间尺度差异巨大
- 职业层面：行业协会/监管机构的组织化程度在不同行业/国家差异极大——有 FAA 级别组织力的行业屈指可数
- 技术层面：在缺乏全球协调的情况下，监管套利几乎不可避免——企业迁移到监管最宽松的市场

缓解方向：

- "最小可行制度"（MVI）从最容易的行业（医疗——已有严格执业标准体系）开始试点
- "软性制度"先行：认证标签 + 消费者教育 + 保险费率差异化
- 区分民用和特殊用途（军方/情报）两个治理域——不同路径

6.3 四个"不推进"区的可执行性困境

问题：自主道德判断系统、实时社会判断替代等红线，在开源模型生态中几乎无法全球执行。即使领先 AI 公司遵守，开源模型（Llama、DeepSeek 等）+ 各国小型 AI 公司 + 独立开发者的组合，意味着阻止这些应用的出现几乎不可能。具体风险：

- "红线漂移"——今天禁止"实时社会判断替代"，明天以"社交辅助""情感支持""关系教练"名义实质上实现同一功能
- 监管套利——不同国家对"道德判断系统"的定义和限制差异巨大
- 军方/情报机构的豁免——安全敏感领域的 AI 应用往往不受民用伦理框架约束

缓解方向：

- 将"红线定义"转化为可检测的技术特征（如系统是否在实时互动中接收社会情境输入并输出判断建议），便于监管识别
- 开源社区自律：在主流开源许可证中增加"禁止用于特定社会型直觉替代应用"条款（执行力存疑但有信号效应）
- 建立"红线监测"机制——不是阻止开发，而是公开监测和点名——透明化本身就是一种约束

6.4 退化监测系统的成本与隐私困境

问题："直觉退化纵向监测系统"按子类型 x 人群追踪直觉能力变化，涉及四个关键指标。建设和维护成本以千万/亿美元计，且涉及高度敏感的心理/行为数据。具体障碍：

- 基线数据获取：在 2026 年——大多数人已经日常使用 AI——如何获取"无 AI 辅助下的独立判断准确率"基线数据？
- 测试标准化：四个子类型的"标准测试"尚未存在（OQ16）
- 隐私：追踪个人直觉退化数据涉及高度敏感的心理/行为数据——隐私保护框架尚未讨论

缓解方向：

- "自然实验"方法：利用现有数据（如医疗 AI 部署前后医生独立诊断率的变化）作为退化指标
- 分阶段建设：先建设感知型监测（数据最容易获取），逐步扩展
- 与企业合作获取匿名化的使用行为数据（用户对 AI 建议的接受率、修改率）

6.5 意外后果

意外后果 1：教育不平等加剧强制"无 AI 独立判断训练"可能导致：富裕家庭在校外大量使用 AI 辅助，贫困家庭在被强制"独立"的环境下接受教育——可能进一步扩大而非缩小能力差距。"被保护脱离 AI 的弱势群体"vs"自由使用 AI 的强势群体"——这个矛盾需要被正视。意外后果 2：特殊群体的服务缺口严格限制 AI 在社会型直觉领域（如实时互动中的 AI 辅助），可能影响：孤独症患者的社交辅助工具、社交焦虑患者的 AI 练习伙伴、语言障碍者的沟通辅助。这些群体的需求不应被忽略——需要设计豁免机制。意外后果 3：人优先协议在紧急场景的延迟风险在医疗急救、危机干预等时间敏感场景，强制"人先判断"的延迟可能造成实际伤害。需要明确的例外清单和豁免条件。

例外协议（时间敏感场景）：在医疗急救、危机干预等时间敏感场景中，"人先判断"压缩为"秒级初步评估（triage 级判断）"，而非完整诊断。AI 辅助与初步评估同步进行，人的角色从"先完整判断"降级为"先方向性把关"。这一例外不改变铁律 1 的核心精神——人仍承担初始认知责任，但承认时间约束下的责任分层。triage^T 在此指在资源/时间约束下对紧急程度的快速分级，而非最终决策。

意外后果 4："不推进"本身可能延缓有益研究"不推进道德型 C"的判断可能被过度解读——可能阻碍对"AI 如何更好地辅助道德反思（而非替代道德判断）"的有益研究。需要区分"不做判断替代"和"不做分析辅助"。

6.6 互补关系的认知负荷条件

来自本项目的实证观察——当人同时维护多个项目时，人机互补关系不是二值的（有效/失效），而是一条连续的衰减曲线。

核心发现

v2.0 此前隐含假设：如果人在理想条件下可以纠正 LLM 的偏误，那么这种互补在所有条件下都成立。5/22 的实证数据否定了这个假设。人类三种用于纠正 LLM 偏误的直觉能力，按认知负荷敏感性排序：

直觉能力	对抗的 LLM 偏误	负荷敏感性	高负荷退化表现
不确定性体感	过度自信（数据不足时仍输出自信答案）	最高	中等偏误被"看起来合理"覆盖；只能感知极端过度自信
独立立场锚	迎合（RLHF 最大化用户满意- > 附和人）	中	迎合被接受为"分析得不错"；疲惫时倾向同意而非质疑
情境独特性感知	模板套用（模式匹配->"这像 X" 而非"这不同"）	最低	框架级错误仍可察觉，但细节偏差漏过

这三种能力按序失效——不确定性体感最先退化，情境独特性感知最后退化。这解释了为什么在高负荷场景中，人能抓到框架级错误（"整个分析框架不对"）但抓不到细粒度偏误（过度自信的措辞、逐条的迎合）。

互补退化曲线

[概念性示意图 • L1:] 基于 N=1 观察的初步建模——5/22 实时观测首次揭示了互补退化的方向性，但曲线的量化形态（斜率、拐点位置、量化互补质量的 Y 轴数值）是理论推演。需要更大规模用户研究（异构项目类型、不同认知负荷水平、纵向跟踪）来验证。PDF 版本中包含该曲线的概念示意图。

退化沿五个阶段渐进：

阶段	退化状态	典型特征	人类仍能捕捉	开始漏过
理想互补	无退化	每条判断都经过独立的框架级审查	逻辑跳跃、证据不足、隐性假设	—
有效互补	轻度	大部分判断经过审查，偶有跳过	框架级错误	偶有措辞偏差
退化互补	中度	审查频率下降，注意力集中在显眼错误	明显逻辑矛盾	细粒度偏误、过度自信措辞
边际互补	重度	仅能抓框架级错误	"整个分析方向不对"	选择性引用、确认偏差嵌入
近失效	极重	橡皮图章——"看起来对就行"	极少数	几乎所有偏误（包括框架级）

- "并行项目有限数量"不是效率建议，是互补关系的存在条件。超过可持续阈值时，人仍然可以"完成"所有判断节点，但判断质量已经从充分互补退化为边际互补。阈值的具体数量因是否部署二阶审计代理而异——这是一个需要持续校准的变量，而非固定数字。
- 不确定性体感是最脆弱的互补维度——它消耗持续的怀疑姿态，在高负荷时最先失效。不确定性体感失效时，人不再追问"证据等级够吗？"而只问"结论看起来对吗？"
- 异构模型对撞可部分补偿人的审查深度不足——不同模型的 RLHF 偏好不同，偏误不完全相关。但模型都没有"不确定性体感"，对过度自信的检测可能仍然不足。

两阶段互补架构（实验性）

基于上述发现，提出一个实验性的互补架构：

阶段 1：异构 Agent 交叉审查——补偿模型偏误相关性（不同训练数据→ 偏误不重叠）阶段 2：人的裁决——仅裁决 Agent 间分歧（而非逐条审查），利用人的互补直觉但控制在低负荷

这个架构的理论优势：将人的认知资源集中到"Agent 之间不一致的地方"——而非平摊到所有内容上。

与已有理论的衔接

- 本发现不改变直觉四子类型框架——它补充了每个子类型对认知负荷的敏感性
- 社会直觉（独立立场锚）和元认知直觉（不确定性体感、情境独特性感知）对负荷高度敏感
- 身体直觉（具身）相对稳定——但它不参与多项目文本审查场景

互补增益：认知扩展的另一面

前文描述的互补退化曲线不是互补关系的全部。来自本项目的实践观察和认知科学文献共同指向一个对称的方向：在适当条件下，LLM 辅助可以产生认知增益。

理论基础：

- 认知卸载的解放效应 [L4]: Sweller (1988) 的认知负荷理论有一个常被忽略的推论——当外在认知负荷被移除时, 释放的工作记忆容量可用于更高层次的认知操作。LLM 处理信息检索、初始框架生成、格式化输出——释放出的资源被重新分配到跨领域概念连接和框架完整性审查。
- **ZPD 脚手架** [L4]: Vygotsky (1978) 的最近发展区理论——学习者在" 独自能达到的水平" 和" 在帮助下能达到的水平" 之间存在一个区间。LLM 作为脚手架让人处理比独自处理更复杂的问题, 并在过程中内化新能力。关键区分: 脚手架被撤走后能力提升了一——这与退化不是矛盾, 而是取决于使用的元认知姿态 (脚手架模式 vs 外包模式)。
- 扩展心智 [L3]: Clark & Chalmers (1998) ——持续性 LLM 协作使工具成为认知系统的一部分。当满足持续可用、自动信任、可随时访问三个条件时, LLM 从" 工具" 变为" 认知系统的扩展"。
- 概念组合增强 [L3-L4]: Fauconnier & Turner (2002) 的概念整合理论 + Koestler (1964) 的" 双关联想"——创造力的核心是连接此前不相关的认知矩阵。LLM 降低跨领域搜索成本, 使概念组合和类比迁移更频繁——表现为" 触角伸开、地图点亮"。
- 元认知外部化 [L2-L3]: 与 LLM 的对话成为" 大声思考" 的外部化——让人更清晰地看到自己的推理过程, 更频繁地问自己" 这个前提假设是什么? 有没有替代框架? "

核心命题:

> 人机互补不是单一方向的过程。它在不同条件下呈现为退化或增益——两者不是互斥的, 可以在同一个体的不同时段、不同项目中交替出现。关键变量不是" 是否使用 LLM", 而是使用的元认知姿态: 人是在" 让 LLM 替我判断" 还是" 让 LLM 帮我看到更多可能性"。

>

一个未解决的张力: 增益的前提 (元认知姿态活跃) 在退化发生时 (B2 元认知遮蔽) 恰恰最容易被破坏。这意味着增益-退化的转换可能不是平滑的——一旦越过退化阈值, 元认知遮蔽可能加速从" 增益区" 坠入" 衰减区"。这个内循环的动力学是当前框架未建模的, 需要纵向跟踪来检验。[L1: 理论推演]

对治理框架的修正: 三条铁律中的" 让人先判断" 不仅是退化防御——它是认知增益的激活条件。人先做判断再比较 LLM → ZPD 脚手架模式 → 能力内化。LLM 先建议人确认 → 外包模式 → 能力退化。同一个 LLM, 同样的信息, 两种模式产生相反的认知效果。更多详细论证和文献参考见补充材料。。

7 完整开放问题清单 (38 个)

以下 38 个开放问题按项目阶段排列, 每条标注了优先级 ($P0/P1/P2$)。P0 = 直接影响第四阶段路线图实施, 需优先验证; P1 = 重要但可在 P0 之后推进; P2 = 长期研究方向。每个都经过了讨论和外部评审的交叉推演。

7.1 第一阶段：纵深解剖（OQ1-12）

- OQ1 [P1]: RLHF 的问题出在信号类型还是时间结构 (batch vs 不可逆序列)?
- OQ3 [P1]: 时间结构——人类直觉在不可逆时间流中形成, LLM 训练可回滚
- OQ3 [P1]: LLM 自纠错失败主因: 代价感知缺失? 停止判据缺失? confabulation?
- OQ4 [P2]: 能否设计" 犯错代价训练"——奖励不确定时不乱改?
- OQ5 [P2]: 自主意识是否是代价敏感性的必要前提?
- OQ6 [P1]: 稀疏注意力能从" 节省计算" 升级到" 模仿人类忽略"? 需要 gate→attend?
- OQ7 [P2]: embedding 空间已有类似 chunk 结构? 问题在 chunk 质量还是 gate?
- OQ8 [P2]: " 主动忽略不相关" 如何 reward? 需要注意力效率指标?
- OQ9 [P2]: as-if body loop 能否在 LLM 实现? 显式模块还是隐式编码?
- OQ10 [P2]: 不可回避性三条件中 LLM 最可能突破哪个?
- OQ11 [P1]: 如果道德直觉 = 躯体标记, LLM 道德推理的根本局限?
- OQ12 [P2]: Collins interactional expertise 能否通过" 在线人-in-the-loop 社会化" 实现?
- OQ13 [P0]: 硬件级不可绕过中断实验能否验证" 不可回避性 > 信号内容"?

7.2 第二阶段：横向扫描（OQ14-20）

- OQ14 [P0]: 如何设计比 RLHF 更好的真实后果反馈信号?
- OQ15 [P1]: LLM 道德偏差是否因 fine-tuning 哲学 (CAI/RLHF/GRPO) 而异?
- OQ16 [P0]: 高保真社会直觉测试 (多通道 + 实时代价 + Agent 交互式) 的设计标准?
- OQ17 [P2]: 概念型" 方向感" 缺失——能否通过自我对弈模拟?
- OQ18 [P1]: AlphaProof 式 RL+ 搜索代替代价压缩在非形式化领域的上限?
- OQ19 [P2]: 概念型 anomaly detection——LLM 是否有功能等价?
- OQ20 [P0]: 能否让 LLM 在训练中产生真实认知挫折来培养" 方向感"?
- OQ21 [P1]: 是否存在功能等价但无身体标记的道德直觉替代路径?

7.3 第二阶段外部评审补充（OQ22-32）

- OQ22-26 [P1]: sycophancy 危险性、过度自信传递、元校正实现、GPS 式社会直觉退化、协同生成翻转、不同 fine-tuning 哲学的偏差差异
- OQ28-28 [P1]: Social Turing Test 2.0 可行性、双通道对称设计
- OQ30-30 [P0]: RLHS 模拟后果保真度上限、分层后果暴露达标标准
- OQ32-32 [P0]: 文化维度作为第三轴操作化、发展轨迹盲点——LLM 能否通过" 社会化训练" 获得部分社会直觉?

7.4 第四阶段：综合输出（OQ34-38，新增）

- OQ34 [P0]: 感知型中空期"静默失效"检测——如何让 AI 在分布外/低置信度强制标注"我不知道"?
- OQ35 [P0]: 社会型直觉退化是否有"敏感期"——类似语言习得? 年轻一代的不可逆窗口?
- OQ36 [P1]: 道德型直觉退化是"退化"还是"从未发展"? 政策含义完全不同
- OQ37 [P0]: 人优先协议的顺从率——人先判断、AI 后给不同意见时, 人改判断的概率? 子类型差异?
- OQ38 [P1]: 退化监测早期预警指标体系——具体指标和触发阈值?
- OQ39 [P0]: 文化维度作为互补地图第三轴——互补地图投影是否结构性变化?

8 参考文献

以下为本文引用的全部文献, 统一编号。正文中不再单独标号——每项文献的关键贡献已在引用处说明。格式: 编号、作者/来源、标题、出处/年份。

8.1 认知科学与心理学

[1] Chase, W. G. & Simon, H. A. "Perception in Chess." *Cognitive Psychology*, 1973. (chunking 理论的奠基性研究——专家通过大量经验将信息压缩为可快速调用的组块) [2] Haidt, J. "The Emotional Dog and Its Rational Tail: A Social Intuitionist Approach to Moral Judgment." *Psychological Review*, 2001. (社会直觉主义模型——道德判断是情感驱动的快速反应, 理性是后续合理化) [3] Damasio, A. R. *Descartes' Error: Emotion, Reason, and the Human Brain*. Putnam, 1994. (躯体标记假说的原始提出——身体信号帮助标注选项的情绪价值, 引导决策) [4] Damasio, A. R. *The Feeling of What Happens: Body and Emotion in the Making of Consciousness*. Harcourt, 1999. (核心意识的躯体基础——扩展了躯体标记假说至意识层面) [5] Maia, T. V. & McClelland, J. L. "A Reexamination of the Evidence for the Somatic Marker Hypothesis." *PNAS*, 2004. (对 SMH 原始形式的系统性批评——有意识知识足以解释 IGT 表现) [6] Fellows, L. K. & Farah, M. J. "Different Underlying Impairments in Decision-Making Following Ventromedial and Dorsolateral Frontal Lobe Damage in Humans." *Cerebral Cortex*, 2005. (VMPFC 患者在 IGT 中失败可能主要是 reversal learning 缺失而非躯体标记缺失) [7] Collins, H. "Interactional Expertise as a Third Kind of Knowledge." *Phenomenology and the Cognitive Sciences*, 2004. (互动专长——社会性知识可脱离身体实践, 但通过深度语言浸入获得) [8] SMH 多水平逻辑回归元分析. *Cognitive, Affective, & Behavioral Neuroscience*, 2025. (对躯体标记假说最新元分析——修正版本 as-if body loop 成立, 原始因果版本证据薄弱) [9] 眼动追踪: 专家 vs 新手棋类眼动对比. PMC4142462. (专家注视点少且集中在关键区域——选择性忽略的实证) [10] 中经网 2024: 68% 受访者自感线下社交能力退化调查.

8.2 预测加工与主动推理

[11] Friston, K. "The Free-Energy Principle: A Unified Brain Theory?" *Nature Reviews Neuroscience*, 2010. (自由能原理的奠基性阐述——大脑作为预测机器, 最小化 free energy) [12] Parr, T., Pezzulo, G., & Friston, K. J. *Active Inference: The Free Energy Principle in Mind, Brain, and Behavior*. MIT Press, 2022. (主动推理的权威教科书——精度加权作为核心机制的系统阐述) [13] Hohwy, J. *The Predictive Mind*. Oxford University Press, 2013. (预测加工理论——大脑是被预测误差驱动的推理引擎) [14] Seth, A. K. & Friston, K. J. "Active Interoceptive Inference and the Emotional Brain." *Philosophical Transactions of the Royal Society B*, 2016. (内感受的主动推理——身体内部信号的精度调节) [15] 保留位——原 Zander et al. 引用经多轮独立文献检索无法确认存在, 已移除。该位置原为直觉-EFE 连接的理论锚点之一, 现仅依赖 Parr et al. [12]。FE 连接的理论锚点之一, 现仅以 Parr et al. [12] 为支撑, 该连接的实证地位降为 L2。

8.3 AI 安全与人机协作

[16] Köbis, N., Rahwan, Z., Rilla, R., et al. "Delegation to artificial intelligence can increase dishonest behaviour." *Nature*, 2025. (AI 委托决策使作弊行为显著增加——对照组约 5%, AI 委托条件下大幅上升, 效应幅度因实验条件而异) [L4: 实验证据, 来自单次实验——需独立复制才升 L5] [17] Cheung, A. et al. 道德偏差研究. *PNAS*, 2025. (LLM 在道德判断中表现出系统性偏差) [18] 道德脆弱性研究. arxiv:2603.05651, 2025. [19] 吹哨人困境——LLM 在社会两难中的表现. NeurIPS, 2025. [20] SJT 超人类表现. *Nature Scientific Reports*, 2024. (LLM 在社会情境判断测验中系统性超越人类——但存在具身性缺口) [21] Bainbridge, L. "Ironies of Automation." *Automatica*, 1983. (自动化悖论——引入自动化降低了操作者技能, 当自动化失效时操作者无法接管) [22] Elish, M. "Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction." *Engaging Science, Technology, and Society*, 2019. (道德挤压区——责任被推到系统中最脆弱的人身上) [23] Vallor, S. "Moral Deskilling and Upskilling in a New Machine Age." *Philosophy & Technology*, 2015. (道德去技能化概念的最早提出——技术外包导致的道德能力退化) [24] Gerlich, M. / Lee et al. / Kosmyna et al. 认知去技能化研究. 2025. (AI 辅助导致的多领域认知能力退化) [25] "Brainrot: Deskilling and Addiction are Overlooked AI Risks." *FAccT*, 2026. (将认知去技能化列为 AI 安全核心议题的里程碑论文) [26] Cabitza, F. et al. "The Human-First AI Protocol in Medical Diagnosis." 2023. (医疗诊断中人优先 AI 协议——证明减少自动化偏差的效果) [27] Buçinca, Z. et al. "Cognitive Forcing Functions Reduce Over-Reliance on AI." *CHI*, 2021. (认知强制函数——延迟 AI 建议呈现可减少过度依赖) [28] 35 项自动化偏差元分析. (AI-first 协议比 Human-first 协议显著增加自动化偏差的系统综述) [29] 放射科 on-demand AI 模式下的 upskilling 效应. *Insights into Imaging*, 2024. [30] JAMA 2023: 放射科住院医师独立读片能力下降 15-30%。

8.4 LLM 技术与工程

[31] Self-Correction as Feedback Control. arxiv 预印本, 2025. (EIR/ECR 框架——只有 EIR<0.5% 的模型自纠错才不退化) [L3: 预印本级别证据] [32] Learning to Think Fast and Slow. NeurIPS, 2025. (直觉和推理可以分离训练——系统 1/系统 2 的工程实现) [33] CBDQ. arxiv:2410.01739, 2024. (在 RL 中引入主观信念建模——向代价敏感性的一步尝试) [34—35] 保

留位——编号保留，内容待补充。[36] AlphaProof. DeepMind, 2024. (RL+ 搜索在 IMO 数学证明中达到银牌——概念型直觉封闭域的里程碑) [37] Hu et al. 自建模机器人. *Nature Machine Intelligence*, 2025. (机器人通过自身运动数据学习身体模型——具身 AI 的最新前沿) [38] Liu et al. 过度自信传递——LLM 的确定性表达如何影响用户校准. 2025.

8.5 哲学与治理

[39] Jennings, A. & Lott, M. "Moral Outsourcing and the Destruction of Agency." *Philosophy & Technology*, 2025. (道德外包对主体性的破坏——身份退位的哲学论证) [40] EU AI Act. (四级风险分类——分层监管的国际法先例)

9 阅读指南：本文件与其他项目文件的关系

你要找什么	看哪个文件
项目全貌和理论框架（为什么、是什么）	本文
可操作的互补地图 v2.0 + 协作协议 + 进化路线图（做什么、怎么做）	综合输出（内部存档）
产品设计规范（ PRD 级）	产品化实施指南（Kimi 起草中）
核心概念的测量与验证方法	操作化附录
跨文化适用性评估	跨文化附录（Kimi 起草中）
10 页决策者摘要	执行摘要（Kimi 起草中）
实施风险与意外后果	本文第六节
每场讨论的详细论证过程	2.1、2.2、3.1 AxC
外部 agent 独立评审/推演全文	hunyuan 第一轮、kimi 第一轮、hunyuan 第二轮、kimi 第二轮、hunyuan AxB、kimi BxC
kimi 群三份评审报告	表达质量、实用价值、创新贡献

10 附录

10.1 附录 A：场景权重矩阵

四直觉子类型在理论上平权——但不同应用场景下它们的相对分析权重差异巨大。这不是"某些子类型不重要"——而是"不同场景关心不同的问题"。

应用场景	感知型	概念型	社会型	道德型	主导问题
AI 竞争格局分析					谁赢？护城河在哪？
教育评估与设计					学生该学什么？AI 该替什么？
医疗 AI 部署					安全边界在哪？诊断责任谁担？
产品 UX 设计					用户感知到差异吗？信任如何建立？
军事/安全应用					判断速度 vs 判断后果——谁承担代价？
日常效率工具					快就行——社会型退化不在议程上

使用说明：

- 五星 = 该场景中此子类型是核心分析维度，不可跳过
- 一星 = 此子类型在该场景中几乎不相关（如日常效率工具不需要道德型分析）
- 权重差异不影响框架的理论完整性——框架覆盖了所有子类型。权重差异影响的是分析聚焦度——在具体场景中，应该把有限的精力投在权重最高的子类型上

10.2 附录 B：盲区登记册

本文的理论框架配有独立的盲区登记册——为 8 个核心假设逐一写下明确的推翻条件和当前信号。盲区登记册每 3-6 个月更新一次。关键假设的脆弱性速览：

- 假设 3（构成性退化）：框架的经验性阿喀琉斯之踵——零纵向因果证据
- 假设 8（命题独立性）：命题 1 和命题 2 指向同一现象的两个描述层次。推翻条件：发现二者可分离
- 假设 1（四子类型划分）：理论上合理但未经因子分析独立验证
- 假设 5（B vs C 竞赛时序）：两个变量各自不确定，乘积更不确定
- 假设 2（具身性缺口）：当前所有证据与框架一致，推翻概率极低

读者和引用者应了解：" 尚未被推翻"/=" 已被证实"。本文处于 Popper 所说的" 经受住了检验但未被证实" 状态。这在理论早期阶段是正常的，但需要坦诚的自我认知。

10.3 附录 C：场景权重矩阵（详细版）

完整场景权重矩阵可向作者索取。